REGEX تنفيذ حمزة السعدي

ما هي التعابير المنتظمة Regex :

هي عبارة عن patterns تستخدم ل : patterns match character combinations in strings

فوائد استخدام التعابير المنتظمة:

- يمكن انشاء تعبير منتظم للتحقق من اي نص موجود لدينا
 - تبقى الكود نظيف
- لها سرعة في الاداء والتحقق بدل من وضع جمل شرطية IF-ELSE

سلبيات استخدام التعابير المنتظمة

- صعوبة انشاءها
- تحتاج لفترات طويلة من التجريب على البيانات ومعرفة شكل البيانات من اجل تصميم نمط معين لها
 - على مستوى الموارد: يمكن ان يحتاج موارد عالية لتنفيذ pattern معقد

مثال:

1- تم سحب مواصفات هاتف Samsung Galaxy S23 من موقع Mobolist يكون حسب الشكل الاتي :

Samsung Galaxy S23 Ultra 6.8" inches,,8/12 GB,Quad,,5000 mAh,1440x3 088 pixels, Dynamic AMOLED 2X,501 ppi, Gorilla Glass Victus 2,200 MP, f/1.7, (wide), OIS,10 MP, f/4.9, (periscope telephoto), OIS, 10x optic al zoom,10 MP, f/2.4, (telephoto), OIS, 3x optical zoom,12 MP, f/2.2, 120 (ultrawide), Super Steady video,45W Wired,65% in 30 min,10W Wireless,4.5W Reverse Wireless 2023,February,01,Snapdragon 8 Gen 2,4 nm,Oct a-core (1x3.2 GHz Cortex-X3 & 2x2.8 GHz Cortex-A715 & 2x2.8 GHz Cortex-A710 & 3x2.0 GHz Cortex-A510), Adreno 740,Single,12 MP, f/2.2, (wide),256/512/1000GB,UFS 4.0,No microSD, Android 13,One UI 5

.1,Stereo Speakers ,Tuned by AKG,32-bit/384kHz audio ,Fingerprint: Un der display,Accelerometer,Gyro,Proximity,Compass,Barometer,234 g, Gla ss front (Gorilla Glass Victus 2), glass back (Gorilla Glass Victus 2), aluminu m frame,Nano-SIM and eSIM or Dual SIM (2 Nano-SIMs and eSIM , dua l stand-by),IP68 dust/water resistant ,Armor aluminum frame ,Stylus (Bluet ooth integration, accelerometer, gyro),NFC,120Hz,HDR10+,Bluetooth 5 .3,USB Type-C 3.2 1,200

2- نقوم باستخراج المواصفات حسب التعبير المنتظم الاتي :

```
patterns = {
'resolution_pattern' : r'\d+x\d+\s*pixels',
'display_pattern' :r'(\b(?:PLSLCD|\w+\s+AMOLED\s\w+|Foldable OLED|Super
AMOLED|Super AMOLED\+|IPS LCD|AMOLED|Foldable LTPO AMOLED|Foldable LTPO2
OLED|TFT LCD|TFT|Fluid AMOLED|OLED|Super Retina XDR OLED|LTPO Super Retina
XDR OLED)\b)',
'number_of_cameras_in_phone:'r'\b(Single|Dual|Triple|Quad|Penta|Hexa|Oct\b
'ppi_pattern' : r'\d+\s*ppi',
'inches_pattern' : r'\b\d+\.\d+\"\s*inches\b|\b\d+\"\s*inches\b',
'camera_pattern':r'\b(?:f\/\d+\.\d+\\s*MP\\d+x\s*optical\s*zoom\\d+°\\(
.*?\)|OIS)\b',
'capacity_pattern' : r'\d+\s*mAh',
'wired_charging_pattern' : r'\d+W\s*Wired',
'wireless_charging_pattern' : r'\d+W\s*Wireless',
'reverse_wireless_pattern' : r'\b(\d+(\.\d+)?)W\s*Reverse\s*Wireless\b',
'date':r'\b\d{4},(?:January|February|March|April|May|June|July|August|Sept
ember | October | November | December), \d{2}\b',
'chipset_pattern' : r'(?:\b(?:Single|Dual|Ouad|Hexa|Octa|Deca|X-\d+)\b-
)?(?:core\s)?(?:\(\d+[x&]?(?:\d*\.\d+\\d*)?\sGHz.*?\))+',
'process_pattern' : r'\d+\s?nm',
'processer_type':r'(\b(?:Snapdragon|Exynos|Apple\sA|MediaTek|Kirin)\s\d+\s
(?:Gen\s\d+)?\b)|(\bSnapdragon\s\d+[A-
Z]?\b)|(\bExynos\s\d+\b)|(\b(?:MediaTek MT(?:\d{4}[A-Z]?|[6789]\d{3}[A-
```

```
Z]?[A-Z]?|[6789]\d{3}G[0-9]{2,3})|Unisoc (?:SC\d{4}[A-Z]?[A-
Z]?|T\d{3,4})|Snapdragon [0-9]+[+-]? Gen [0-9]+|Apple A(?:1[567]|17)
Bionic|JLQ JR510)\b)|(\b(?:MediaTek Helio [DG][0-9]{2}|MediaTek Dimensity
[0-9]+ 5G|Unisoc (?:SC\d+[A-Z]?[0-9]?[A-Z]?|T\d+)|Snapdragon|Apple A17
Pro)\b)|(\b(?:MediaTek Dimensity 1080|Unisoc (?:6531F|Tiger T616|Tiger
T612))\b)|(MediaTek )',
'qpu_pattern' : r'(Adreno\s\d+|\bXclipse\s\d+\b|\b(?:Mali-
G\d+\s*(?:MC\d+|MP\d+)?|PowerVR GE8320|IMG8322|Unisoc T107|Apple GPU
|NA|Unknown)\b|\b(?:PowerVR|Unknown|(Apple GPU)))',
"os":r'\b(Android|i0S|Windows\sPhone|BlackBerry\sOS|One\sUI|OxygenOS|MIUI|
HarmonyOS)\s(\d+(\.\d+)?)\b',
'space_limit_pattern' :r'\b(?:\d+/\d+/\d+GB|\d+/\d+GB|\d+GB|\b128MB\b)\b',
'UFS' : r'\bUFS\s(\d+\.\d+)\b',
'microsd_pattern' : r'(\b(?:microSDXC|No microSD|MicroSD support|Nano
Memory|microSDHC)\b)',
'speakers_pattern':r'(Stereo\sSpeakers|Mono\sSpeaker)|(Loudspeaker)|(\b(?:
Stereo speakers | Dual Speakers ) \b)',
'tuned_pattern' : r'Tuned\sby\sAKG',
'audio_quality_pattern' : r'\d+-bit/\d+kHz\s*audio' ,
'fingerprint_pattern' : r'Fingerprint:\sUnder\sdisplay|Fingerprint:\sRear-
mounted|Fingerprint:\sSide-mounted|Face ID',
'other_sensors_pattern':r'(Accelerometer|Gyro|Proximity|Compass|Barometer,
'weight_pattern' : r'\d+\s*g',
'sim_pattern' : r'(?:Nano|Micro|Standard|eSIM)(?:-
SIM)?|\bDual\sSIM(?:\s\(\d\s(?:Nano|Micro|Standard|eSIM)(?:-
SIM)?(?:s)?(?:\sand\s(?:Nano|Micro|Standard|eSIM)(?:-SIM)?)?(?:s)?\))?\b',
'protection_pattern' : r'(IP\d+\s*dust\/water
resistant \bIPX\d{1,2}\s(water)?\sresistant\b|\bIPX\d{2}\b)',
'usb_pattern' : r'(\b(?:microUSB 2\.0|USB Type-C|USB 2\.0|\bUSB\sType-
C\s\d+\.\d+\b\USB 2\.0 1)\b)'
'bluetooth_pattern' : r'Bluetooth\s(\d+\.\d+)',
'features_pattern' : r'Stylus \(.*?\)',
'hdr_pattern' : r'HDR\d+\+?',
'refresh_rate_pattern' : r'\d+Hz',
'nfc_pattern' : r'NFC',
}
```

```
name: Samsung Galaxy S23 Ultra
resolution_pattern: ['1440x3088 pixels']
price: 1,200
display_pattern: ['Dynamic AMOLED 2X']
number_of_cameras_in_phone: ['Quad']
ppi_pattern: ['501 ppi']
inches_pattern: ['6.8" inches']
camera_pattern: ['200 MP', 'f/1.7', 'OIS', '10 MP', 'f/4.9', 'OIS', '10x optical zoom', '10
MP', 'f/2.4', 'OIS', '3x optical zoom', '12 MP', 'f/2.2', '12 MP', 'f/2.2']
capacity_pattern: ['5000 mAh']
wired_charging_pattern: ['45W Wired']
wireless_charging_pattern: ['10W Wireless']
reverse_wireless_pattern: [4.5]
date: ['2023,February,01']
chipset_pattern: ['Octa-core (1x3.2 GHz Cortex-X3 & 2x2.8 GHz Cortex-A715 & 2x
2.8 GHz Cortex-A710 & 3x2.0 GHz Cortex-A510)']
process_pattern: ['4 nm']
processer_type: [('Snapdragon 8 Gen 2')]
gpu_pattern: [('Adreno 740')]
os: [('Android', '13'), ('One UI', '5.1')]
space_limit_pattern: ['256/512/1000GB']
UFS: ['4.0']
microsd_pattern: ['No microSD']
speakers_pattern: [('Stereo Speakers')]
tuned_pattern: ['Tuned by AKG']
audio_quality_pattern: ['32-bit/384kHz audio']
fingerprint_pattern: ['Fingerprint: Under display']
other sensors pattern: ['Accelerometer', 'Gyro', 'Proximity', 'Compass', 'Barometer']
weight_pattern: ['234 g']
sim_pattern: ['Nano-SIM', 'eSIM', 'Dual SIM']
protection_pattern: [('IP68 dust/water resistant')]
usb_pattern: ['USB Type-C']
bluetooth_pattern: ['5.3']
features_pattern: ['Stylus (Bluetooth integration, accelerometer, gyro)']
hdr_pattern: ['HDR10+']
refresh_rate_pattern: ['120Hz']
nfc_pattern: ['NFC']
```

الا الا الا الا NLP USING NER

تقنية استخراج الكيانات المعنوية (NER) لها العديد من المزايا والمميزات، من بينها:

- 1. دقة عالية: تقنية NER تستخدم نماذج معرفة مسبقًا للاستخراج، مما يزيد من دقة عملية استخراج الكيانات.
 - 2. فهم السياق: تقنية NER تأخذ في الاعتبار السياق الذي يتواجد فيه الكيان، مما يساعد على فهم المعنى والعلاقات بين الكيانات.
- 3. سهولة التعديل: يمكن تحديث نماذج NER بسهولة لتعلم الكيانات الجديدة أو التعديل على الكيانات الموجودة.
 - 4. قابلية التوسع: يمكن توسيع نطاق تقنية NER لاستخراج مجموعة متنوعة من الكيانات والمفاهيم.
 - فعالية في معالجة النصوص الكبيرة: تقنية NER تعتبر فعالة في معالجة النصوص الضخمة والكبيرة بسرعة ودقة.

سلبيات ال NER:

بالرغم من المزايا الكثيرة التي توفرها تقنية استخراج الكيانات المعنوية (NER)، إلا أنها تواجه بعض السلبيات والتحديات، من بينها:

- 1. صعوبة التعامل مع اللغات غير اللاتينية: قد تواجه تقنية NER صعوبة في استخراج الكيانات من اللغات غير اللاتينية نظرًا لتنوع هياكلها وصيغها.
 - 2. التحدي في التعرف على الأسماء الخاصة: قد تواجه تقنية NER صعوبة في التعرف على الأسماء الخاصة أو الكيانات غير المعروفة مسبقًا في النصوص.
- 3. تأثير السياق والتضاربات: قد تحدث تضاربات في استخراج الكيانات نتيجة للسياق المحيط بالكلمات، مما يزيد من احتمالية الأخطاء.
 - 4. الحاجة إلى تدريب النماذج: يتطلب استخدام تقنية NER تدريب نماذج معرفة مسبقًا على مجموعات كبيرة من البيانات، مما يتطلب جهدًا ووقتًا لإنشاء نماذج دقيقة.

5. قيود في استخراج العلاقات: تقنية NER قد تواجه صعوبة في استخراج علاقات معقدة بين الكيانات، خصوصًا إذا كانت هذه العلاقات غير واضحة في النص.

مثال:

Code:

```
def extract_spitification(label, text):
   entity = []
   if label == "CAMERA1":
       pattern = r'Selfie camera'
       match = re.search(pattern, text)
           new_text = text[start_index:]
           doc = nlp_ner(new_text)
                for ent in doc.ents:
                        entity.append(ent.text)
   elif label == "CAMERA":
```

```
pattern = r'Main Camera(.*?)Selfie camera'
match = re.search(pattern, text, re.DOTALL)
   new_text = match.group(1)
   doc = nlp_ner(new_text)
   if doc:
       for ent in doc.ents:
               entity.append(ent.text)
   return entity
for ent in doc.ents:
       entity.append(ent.text)
```

هذه الدالة تقوم باستقبال نص والمواصفة المراد استخراجها من النص

r\nVersions: A3094 (International); A2847 (USA); A3093 (Canada, Japan); A3096 (China, Hong Kong)\r\n\r\nNetwork\r\nTechnology\r\nGSM / CDMA / HSPA / EVDO / LTE / 5G\r\n\r\n2G bands\r\nGSM 850 / 900 / 1800 / 1900 -bands\r\nHSDPA 850 / 900 / 1700(AWS) / 1900 / 2100 \r\n\r\n\r\n\r\nCDMA2000 1xEV-DO \r\n\r\n4G bands\r\n1, 2, 3, 4, 5, 7, 8, 12, 13, 17, 18, 19, 20, 25, 26, 28, $30, 32, 34, 38, 39, 40, 41, 42, 46, 48, 53, 66 - A3094\r\n\r\n\r\n\, 1, 2, 3, 4, 5, 7, 8,$ 12, 13, 14, 17, 18, 19, 20, 25, 26, 28, 29, 30, 32, 34, 38, 39, 40, 41, 42, 46, 48, 53, 66, 71 -A2847\r\n\r\n\1, 2, 3, 4, 5, 7, 8, 11, 12, 13, 14, 17, 18, 19, 20, 21, 25, 26, 28, $29, 30, 32, 34, 38, 39, 40, 41, 42, 46, 48, 53, 66, 71 - A3093 \r\n\r\n\r\n\2, 3, 4,$ 5, 7, 8, 12, 13, 17, 18, 19, 20, 25, 26, 28, 30, 32, 34, 38, 39, 40, 41, 42, 46, 48, 66 -A3096\r\n\r\n5G bands\r\n1, 2, 3, 5, 7, 8, 12, 20, 25, 26, 28, 30, 38, 40, 41, 48, 53, 26, 28, 29, 30, 38, 40, 41, 48, 53, 66, 70, 71, 77, 78, 79, 258, 260, 261 28, 29, 30, 38, 40, 41, 48, 53, 66, 70, 71, 75, 76, 77, 78, 79 SA/NSA/Sub6 -A3093\r\n\r\n\1, 2, 3, 5, 7, 8, 12, 20, 25, 26, 28, 30, 38, 40, 41, 48, 66, 70, 77, $78, 79 \text{ SA/NSA/Sub6} - \text{A3096} \ \text{n}\ \text{n}\ \text{n}\ \text{Speed}\ \text{nHSPA}, LTE-A, 5G, EV-DO$ Rev.A 3.1 Mbps\r\n\r\n\r\n\r\nLaunch\r\nAnnounced\r\n2023, September 12\r\n\r\n\r\nStatus\r\nAvailable. Released 2023, September x 0.31 in)\r\n\r\nWeight\r\n201 g (7.09 oz)\r\n\r\nBuild\r\nGlass front (Corning-made glass), glass back (Corning-made glass), aluminum frame\r\n\r\nSIM\r\nNano-SIM and eSIM - International Dual eSIM with multiple numbers - USA Dual SIM (Nano-SIM, dual stand-by) - China\r\n\r\n IP68 dust/water resistant (up to 6m for 30 min)\r\nApple Pay (Visa, MasterCard, AMEX certified)\r\n\r\n\r\nDisplay\r\nType\r\nSuper Retina XDR OLED, HDR10, Dolby Vision, 1000 nits (HBM), 2000 nits (peak) $\r\n\r\n\$ inches, 110.2 cm2 (~88.0% screen-to-body ratio)\r\n\r\nResolution\r\n1290 x 2796 pixels, 19.5:9 ratio (~460 ppi density)\r\n\r\nProtection\r\nCeramic Shield glass r n r n r n r n r n r n S r n S 17, upgradable to iOS 17.2\r\n\r\nCPU\r\nHexa-core (2x3.46 GHz Everest + 4x2.02 GHz Sawtooth)\r\n\q\nQPU\r\nApple GPU (5-core

```
graphics)\r\n\r\n\r\n\r\n\r\nMemory\r\nCard
 slot\r\nNo\r\n\r\nInternal\r\n128GB 6GB RAM, 256GB 6GB RAM, 512GB 6GB
RAM \r \n \r \n \r \n \r \n \r \n \A MP
  f/1.6, 26mm (wide), 1/1.56\", 1.0μm, dual pixel PDAF, sensor-shift OIS\r\n\r\n12
  MP, f/2.4, 13mm, 120° (ultrawide)\r\n\r\nFeatures\r\nDual-LED dual-tone
        flash, HDR (photo/panorama)\r\n\r\nVideo\r\n4K@24/25/30/60fps,
1080p@25/30/60/120/240fps, HDR, Dolby Vision HDR (up to 60fps), Cinematic mode
 (4K@30fps), stereo sound rec. r\n\r\n\r\n\c camera r\n\c
        MP, f/1.9, 23mm (wide), 1/3.6\", PDAF\r\n\r\nSL 3D, (depth/biometrics
                    sensor)\r\n\r\nFeatures\r\nHDR, Cinematic mode
    (4K@30fps)\r\n\r\n\deo\r\n4K@24/25/30/60fps, 1080p@25/30/60/120fps,
     gyro-EIS\r\n\r\n\r\n\r\n\cound\r\n\Loudspeaker \r\n\Yes, with stereo
                                    speakers r n r n 3.5mm jack
   \r \n \r \n \r \n \r \n \r \n \
                   dual-band, hotspot\r\n\r\nBluetooth\r\n5.3, A2DP,
            LE\r\n\r\nPositioning\r\nGPS, GLONASS, GALILEO, BDS,
accelerometer, gyro, proximity, compass, barometer\r\n\r\n Ultra Wideband 2
                   (UWB) support\r\n\r\nEmergency SOS via satellite (SMS
  sending/receiving)\r\n\r\n\r\nBattery\r\nType\r\nLi-Ion 4383 mAh, non-
            (advertised)\r\n\r\n15W wireless (MagSafe)\r\n15W wireless (Qi2) - requires
                                  iOS 17.2 update \ n\ n4.5W reverse
      wired\r\n\r\n\r\n\r\nMisc\r\nColors\r\nBlack, Blue, Green, Yellow,
                  Pink\r\n\r\nModels\r\nA3094, A2847, A3093, A3096,
```

 $iPhone15,5\r\n\r\nSAR\r\n1.01\ W/kg\ (head)$

 $\r \n \r \nSAR EU\r \n 0.98 W/kg (head)$

\r\n\r\nPrice\r\n€ 995.99 / \$ 724.90 / £, 819.00 /

 $82,990\r\n\r\n\r\n\r\n\$

1.12 W/kg (body)

 $0.98 \, \text{W/kg (body)}$

1

```
import re
from spacy import displacy
text="""
r\nVersions: A3094 (International); A2847 (USA); A3093 (Canada, Japan); A3096 (China, Hong Kong)\r\n\r\n\r\nNet

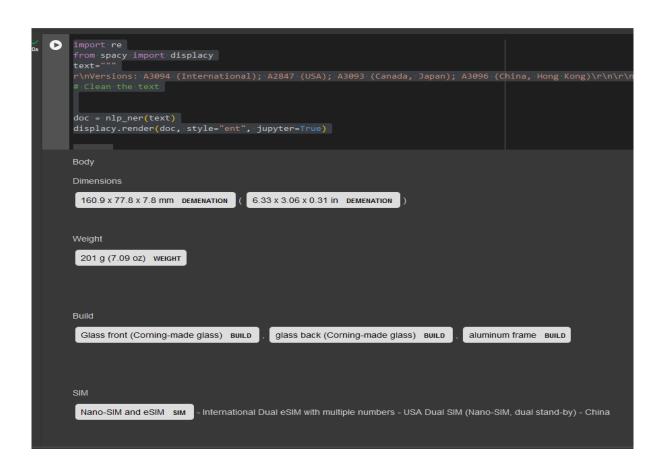
doc = nlp_ner(text)
displacy.render(doc, style="ent", jupyter=True)

Network
Technology

GSM NET / CDMA NET / HSPA NET / EVDO NET / LTE NET /5G

2G bands NET
GSM 850 / 900 / 1800 / 1900 - SIM 1 & SIM 2 (dual-SIM)
```

2



```
import re
from spacy import displacy
text-""
r\nversions: A3894 (International); A2847 (USA); A3893 (Canada, Japan); A3

Clean the text

doc - nlp_ner(text)
displacy.render(doc, style="ent", jupyter=True)

Chipset
Apple A16 Bionic (4 nm) CHIPEST

CPU
Hexa-core (2x3.46 GHz Everest + 4x2.02 GHz Sawtooth) CPU

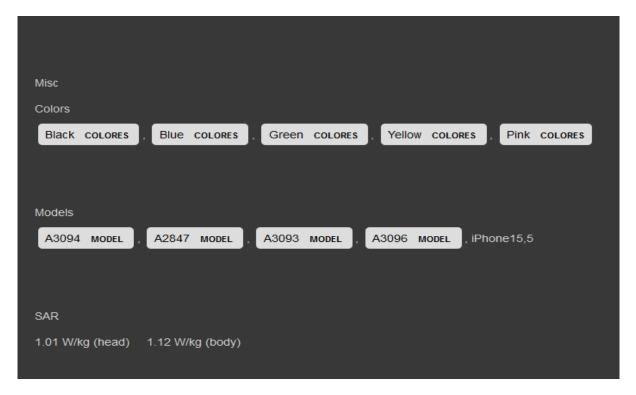
GPU
Apple GPU (5-core graphics) GPU

Memory
Card slot
No
```



Face ID	SENSORES	accelerometer	SENSORES	, gyro	SENSORES	proximity	SENSORES	compass	SENSORES	, barometer Ultra Wideband 2 (UWB) support Emergency SOS via satellite (SMS sending/receiving)
SENSORES										
Battery										
LI-ion 4383 mAh, non-removable BATTAREY										
Charging				_						
Wired, PD	02.0, 50% in	30 min (advertise	ed) CHARGIN	G						







الفروق الرئيسية بين استخدام تقنية ال REGEX (التعابير المنتظمة) وال NER (استخراج الكيانات من النصوص هي كما يلي:

NER	REGEX	من حيث
تعتمد تقنية ال NER على نماذج	تقنية الـ regex تعتمد على تحديد	دقة الاستخراج
معرفة مسبقًا للاستخراج. وبالتالي، قد	أنماط محددة من النصوص لاستخراج	27 - 23 ست س
تكون تقنية الـ NER أكثر دقة في	الكيانات	
استخراج الكيانات		
مكن تحديث نماذج الـ NER	يتطلب تحديث نماذج الـ regex	سهولة التحديث
بسهولة لتعلم الكيانات الجديدة	تعديلات على النماذج الموجودة	
NER بينما قد تكون تقنية ال	تقنية الـ regex قد تكون أكثر	قابلية التعامل مع التغيرات
 أكثر حساسية لهذه التغيرات	قابلية للتعامل مع التغيرات في صيغة	٠. د ن
, , ,	النصوص النصوص	
	3	

الخلاصة:

بشكل عام، يمكن استخدام كل من تقنية الـ regex والـ NER في استخراج الكيانات من النصوص وفقًا لاحتياجات ومتطلبات المشروع المحدد.